Cadeias de Markov para geração de músicas baseadas no soundtrack original de Ace Attorney

Matheus Farnese Lacerda Senna
Departamento de Ciência da Computação, UFMG
senna.matheus@gmail.com

RESUMO

Este trabalho investiga a geração automática de músicas inspiradas na trilha sonora de Ace Attorney utilizando cadeias de Markov de primeira ordem. O modelo, implementado em Python, processa arquivos MIDI e incorpora padrões frequentes maximais para preservar sequências musicais recorrentes. Os resultados indicam que as músicas geradas mantêm características distintivas das composições originais, permitindo sua identificação por uma fã da franquia em todos os casos avaliados. Entretanto, foram observadas dificuldades na sincronização entre pistas instrumentais e na representação de estruturas musicais de longo prazo. Como trabalho futuro, propõe-se aprimorar a coordenação temporal entre os instrumentos.

1. INTRODUÇÃO

As cadeias de Markov (Markov Chains) são modelos matemáticos probabilísticos utilizados para representar sistemas que evoluem ao longo do tempo, nos quais o próximo estado depende apenas do estado atual, e não de toda a sequência de estados anteriores. Formalmente, processo Markoviano é um mecanismo que, dado um estado μ ele gera um novo estado ν de forma estocástica pois para um estado μ específico nem sempre o mesmo estado ν será gerado. Assim, a probabilidade de gerar o estado ν sendo dado o estado μ, será $P(\mu \rightarrow \nu)$, que é chamada de probabilidade de transição ou taxa de transição. As taxas dependem apenas das propriedades dos estados μ e ν, sendo independentes de outros estados pelo qual o sistema tenha passado ou venha a passar. Ou seja, um processo Markoviano não tem nenhum tipo de memória e a probabilidade de gerar o estado ν partindo do estado μ depende apenas dos estados e de nada mais.

A aplicação de um processo markoviano repetidamente para gerar uma sequência de estados é chamada de Cadeia de Markov. Essa metodologia pode ser utilizada para simular cenários estocásticos e, em particular, pode ser utilizada na geração automática de música, ao aprender padrões estatísticos a partir de composições existentes e produzir novas sequências musicais (cadeias) com características semelhantes às do material utilizado no treinamento. Nesse contexto, o "treinamento" nada mais é do que modelar a música como um conjunto de estados e definir probabilidades de transição entre eles. A forma mais simples de se modelar um processo markoviano em uma música é considerar cada nota como um estado e extrair a probabilidade de transição de uma nota dada a anterior. E.g. a sequência de notas B - D - B - C - B - D possui 3 estados (B, C, D) e as probabilidades de transição são (B → C: 0.33, B → D: 0.66, C → B: 1.0, D → B: 1.0). A partir dessa máquina de estados, o processo markoviano seleciona sucessivamente os próximos estados, gerando uma sequência verossímil baseada na máquina de estados que, ao ser interpretada com uma música por uma ferramenta de renderização de áudio, espera-se que carregue semelhanças com a música original e possa ser classificada subjetivamente como uma "melodia", e não apenas barulhos em sequência.

Apesar de sua simplicidade e eficiência computacional, essa abordagem apresenta limitações na representação de estruturas musicais de longo prazo, uma vez que as dependências consideradas são restritas à ordem definida pelo modelo (i.e., quantos estados passados μ são considerados na probabilidade condicional para se gerar o próximo estado ν). Outra limitação está no fato de que músicas feitas por humanos não são arranjos aleatórios e cada nota depende da música como um todo. Portanto, como cada estado nessa abordagem depende apenas do estado anterior, músicas muito complexas provavelmente serão mais difíceis de serem utilizadas como base para o modelo gerar algo verossímil.

Tendo em vista as limitações inerentes à modelagem por cadeias de Markov, o tema escolhido para esse trabalho foi gerar músicas baseadas no soundtrack do jogo Ace Attorney. Esse jogo, lançado inicialmente em 2001 para o console Game Boy Advance, possui músicas curtas e com padrões simples, compostas majoritariamente pelo compositor Masakazu Sugimori. Assim sendo, espera-se que as músicas geradas tenham semelhanças com o soundtrack original e que o modelo consiga representar os padrões e jingles das músicas.

2. TRABALHOS RELACIONADOS

Shapiro e Huber, em [1], investigam a utilização de cadeias de Markov para a geração automática de composições musicais a partir de partituras existentes. A abordagem consiste em representar eventos musicais como estados que representam uma nota individual, um acorde ou uma pausa, incluindo informações sobre sua altura e duração (nota(s), acidentes musicais, oitava, duração e pausa). Os autores apresentam uma implementação em Python que demonstra a aplicação prática do método e que consegue capturar padrões e regularidades de uma composição e representá-los na cadeia gerada. Embora a abordagem ofereça uma alternativa simples e interpretável para a geração musical, sua capacidade de capturar dependências de longo prazo é limitada pelos problemas já citados na seção 1.

Ramanto e Maulidevi [2] propõem um sistema de geração procedural de música baseado em cadeias de Markov, condicionado ao humor especificado pelo usuário. A abordagem utiliza o modelo circumplexo de Tellegen–Watson–Clark para associar diferentes estados de humor a configurações de parâmetros musicais, como andamento, extensão de alturas e predominância de acordes maiores ou menores. A geração é realizada por meio de cadeias de Markov independentes para modelar componentes como notas melódicas, progressões harmônicas, movimentos de oitava e durações. Cada cadeia possui um conjunto de estados diferentes (e.g. a cadeia das notas os estados são as notas musicais (A, B, C, …), na cadeia da duração os estados são (colcheia, semínima, …), etc). O sistema foi implementado em Java com a biblioteca JMusic e avaliado por meio de questionários, alcançando, na terceira rodada de avaliação, taxas de aprovação de 83,5% para a compatibilidade com o humor solicitado e de 86,5% para a adequação da composição musical. Embora os resultados indiquem a viabilidade da geração musical condicionada por humor, a abordagem utiliza probabilidades definidas manualmente e, assim como no trabalho descrito no parágrafo anterior, apresenta limitações na representação de dependências musicais de longo prazo.

Wokhlu [3] investiga a aplicação de cadeias de Markov à composição musical estocástica, apresentando os fundamentos matemáticos do modelo e demonstrando sua utilização na geração de novas sequências musicais a partir de uma composição existente. Em seu experimento, o autor utiliza uma versão de *Jingle Bells* para construir uma matriz de transição a partir das frequências observadas entre objetos sonoros consecutivos. Cada estado é representado por um objeto sonoro composto pela altura da nota, incluindo sua oitava, e sua duração rítmica. A partir da matriz estimada, novas sequências são geradas por amostragem probabilística, preservando características estatísticas locais da composição original. Embora a abordagem demonstre a simplicidade e a aplicabilidade das cadeias de Markov à geração musical,o modelo, assim como nos outros dois trabalhos, também apresenta dificuldades para representar harmonia, estrutura formal e dependências musicais de longo prazo.

Portanto, baseando-se nas referências estudadas, tem-se como objetivo do presente trabalho a geração de uma sequência que capture regularidades nas músicas de Ace Attorney e que preserve alguns desses padrões. Também é esperado que, assim como nos 3 trabalhos citados, o modelo criado tenha dificuldades em criar uma música coesa e harmônica do início ao fim.

3. Método

Os arquivos utilizados como input foram MIDIs dos soundtracks de Ace Attorney disponíveis gratuitamente online em [4]. Para o presente trabalho, foi implementado um gerador em python que constrói uma máquina de estados probabilística para gerar uma cadeia de Markov de primeira ordem (cada estado depende apenas do estado imediatamente anterior). Seguindo a ideia de construir diferentes cadeias de Markov para representar a música presente em [2], para cada track do arquivo MIDI foi construída uma máquina de estados diferentes para modelar apenas aquela track.

Para capturar padrões repetitivos das músicas mais facilmente, antes da construção da máquina de estados, é executado um algoritmo de mineração de padrões frequentes sobre a sequência de entrada. Cada elemento dessa sequência é uma tupla (nota, duração, descanso) extraída do arquivo MIDI. Um padrão de elementos é considerado frequente se ele é maximal com tamanho máximo t e aparece pelo menos k vezes na sequência. t e k são parâmetros do modelo e como default são utilizados t=12 e k=3. Esses valores foram escolhidos empiricamente ao analisar manualmente alguns dos arquivos MIDI utilizados. Esses padrões frequentes maximais são então aglutinados em um único estado. As notas (i.e. tupla (nota, duração, descanso)) que não forem aglutinadas formam um estado sozinhas. A máquina de estados de primeira ordem é então construída normalmente observando-se as transições presentes na sequência.

A abordagem utilizando uma cadeia de Markov de primeira ordem com a adição de padrões frequentes foi escolhida por representar um bom compromisso entre

capturar e repetir características marcantes das músicas sem simplesmente copiá-la, além de ser possível gerar saídas com a mesma essência mas diferenças perceptíveis na melodia utilizando a mesma entrada e parâmetros.

4. Resultados

As músicas geradas demonstraram capacidade de incorporar padrões musicais relevantes e produzir melodias que preservam características estilísticas das composições originais. Entretanto, conforme esperado, o modelo apresentou dificuldades em reproduzir aspectos musicais que dependem da organização e da interação entre as diferentes partes da composição. O principal desafio identificado foi a sincronização entre as tracks.

Na trilha sonora original, cada instrumento desempenha uma função específica na composição, e os instrumentos não necessariamente tocam simultaneamente ao longo de toda a música. Nas sequências geradas pelo modelo, entretanto, todos os instrumentos iniciam a execução no instante inicial e tocam por um número N de notas, definido pelo usuário. Embora os intervalos de descanso sejam preservados individualmente para cada instrumento, o posicionamento das entradas dos instrumentos e os efeitos musicais decorrentes dessa organização temporal não são reproduzidos. Dessa forma, perde-se um aspecto importante da estrutura da composição original.

Apesar dessas limitações, o modelo foi capaz de gerar variações das músicas de Ace Attorney que preservam diversos elementos característicos das composições originais. Para avaliar empiricamente esse resultado, foi realizada uma análise com uma fã da franquia. Ao ouvir as músicas geradas, ela conseguiu identificar corretamente a respectiva música original em todos os casos avaliados. Esse resultado constitui um indício de que o modelo é capaz de preservar características musicais suficientemente distintivas para permitir o reconhecimento das composições de referência.

4.1 Abordagens alternativas

Além do modelo final apresentado neste relatório, foram testadas outras variações, posteriormente descartadas por apresentarem resultados considerados subjetivamente inferiores. Inicialmente, foram utilizados simultaneamente vários arquivos MIDI de músicas distintas, sem diferenciação entre as tracks, para estimar as probabilidades de transição da cadeia de Markov. Essa abordagem não conseguiu preservar padrões musicais relevantes, resultando em composições desorganizadas.
Diante desse resultado, a abordagem foi modificada para utilizar apenas um arquivo MIDI por vez. Foram então construídas cadeias de Markov que consideravam a música como um todo, sem distinção entre as tracks, tratando cada nota individualmente como um estado. Nessa etapa, foram exploradas diferentes ordens para as cadeias, bem como configurações com e sem a representação dos intervalos de descanso entre as notas.

A qualidade das composições geradas por essas variações foi avaliada subjetivamente por meio da audição. Com base nessa avaliação comparativa, o modelo apresentado nas seções anteriores foi considerado o mais adequado entre as abordagens testadas.

5. Conclusão e trabalhos futuros

O presente trabalho utilizou uma abordagem baseada em cadeias de Markov para geração automática de músicas baseadas no soundtrack original do jogo Ace Attorney. O modelo conseguiu gerar com sucesso músicas que mantiveram padrões musicais importantes das melodias originais. Ademais, por ser um modelo estocástico, cada execução dele gera um output diferente, permitindo a geração de músicas diferentes a partir da mesma entrada.

As limitações do modelo são inerentes à forma como as cadeias de Markov são construídas. Por modelarem cada estado como dependente apenas do estado anterior, aspectos musicais que dependem da organização e da interação entre diferentes partes da composição e outras estruturas musicais de longo prazo não são bem captadas pelo modelo.

Para trabalhos futuros, uma importante extensão seria tratar o problema da sincronização de instrumentos e diferentes tempos de entradas deles nas músicas para que cada track gerada harmonize melhor com as outras e gere uma composição mais agradável de se escutar.

6. REFERÊNCIAS

[1] Ilana Shapiro & Mark Huber, "Markov Chains for Computer Music Generation," Journal of Humanistic Mathematics, Volume 11 Issue 2 (July 2021), pages 167-195. DOI: 10.5642/jhummath.202102.08. Available at: https://scholarship.claremont.edu/jhm/vol11/iss2/8

[2] Ramanto, Adhika Sigit, and Nur Ulfa Maulidevi. "Markov chain based procedural music generator with user chosen mood compatibility." International Journal of Asia Digital Art and Design 21.1 (2017)

[3] Parth Wokhlu · 2023 · “Markov Chains and Musical Composition” University of Chicago, Research Experiences for Undergraduates (REU)

[4] https://www.midishrine.com/index.php?id=194